UNIVERSIDAD DE LAS AMÉRICAS

FACULTAD DE INGENIERÍAS Y CIENCIAS APLICADAS DE LA CARRERA
INGENIERÍA EN ELECTRONICA Y AUTOMATIZACIÓN

Probabilidad y Estadística

AVANCE DEL PROYECTO

Luis Guerrero

Arianna Alvarado
Ariel Cisneros
Jordany Quevedo
Gabriela Castillo
Nicolas Villacis

23/10/20269-

1. Contexto y preparación de la base de datos

a. Descripción de la base de datos

Los datos provienen de la base de comercio de mercaderías de la Encuesta Estructural Empresarial (ENESEM), edición 2024, elaborada por el Instituto Nacional de Estadística y Censos (INEC) de Ecuador. La encuesta cubre empresas grandes y medianas, por lo que los resultados no representan a todo el comercio del país. La base registra, para cada empresa, el valor vendido y el costo de ventas de los productos que comercializa. Los montos están expresados en dólares estadounidenses (USD).

Cada uno de los datos representa a un producto comercializado por una empresa, por lo tanto se encontró q varias empresas se mostraban en reiteradas ocasiones en algunos casos 4 en ocasiones y otras hasta 32 veces. La base de datos original contiene 11 217 observaciones, 2 575 empresas y 13 variables. Tras la limpieza se trabajó con 11 121 observaciones.

Las variables principales son: tipo de mercadería (por mayor o por menor), actividad económica, producto, valor vendido nacional, valor vendido al extranjero, valor vendido total y costo de ventas total. Las primeras son cualitativas nominales y las últimas cuatro son cuantitativas continuas.

b. Calidad y limpieza de datos

La base de trabajo es una muestra aleatoria simple de 300 extraídos de la ENASEM 2024. De las 13 variables originales se seleccionaron cinco: Descripción de actividad, tipo de mercadería, valor vendido, costó de ventas, valor vendido nacional.

La revisión en Rstudio arrojó estos resultados:

- No existen valores faltantes, todo está detallado dentro de los 300 registros.
- Los registros duplicados no existen, pero varias empresas han creado distintas versiones para otros diferentes datos.
- Al ser ventas no existen valores negativos ya que dentro de los distintos valores no se encontraron datos con signo negativo.
- La coherencia de los datos es la correcta ya que los montos por individual no supera el valor total nacional.
- Se tomaron en cuenta 9 de las 16 selecciones para el tipo de mercadería.
- Los valores inusuales existen dos ya que hay dos registros con cantidad de 0 ya que estos solo vendieron al extranjero, mientras que hay empresas que registraron el costó de ventas con mayor a la cantidad vendidas uno de ellos registró 1,8 millones de dólares americanos.

2. Variables seleccionadas y preguntas de análisis

Variables seleccionadas

- **Descripción actividad principal-Cualitativa Nominal:**

  La elegimos porque nos permite clasificar a las empresas en sus respectivos sectores macroeconómicos y entender que sector predomina en la muestra

- **Tipo de mercadería- Cualitativa Nominal:**

  Es fundamental para identificar si la naturaleza de las operaciones comerciales de las entidades analizadas se enfoca al por mayor o al por menor

- **Valor vendido total- Cuantitativa Continua:**

  Seleccionada porque es el indicador principal del rendimiento comercial y tamaño de las

operaciones de cada empresa

- **Costos de ventas totales- Cuantitativas Continua:**

  Necesaria para analizar la carga de costos que enfrenta las empresas para poder generar sus ingresos

- **Valor vendido Nacional- Cuantitativa Continua:**

  Nos ayuda a comprender que proporción de los ingresos totales depende exclusivamente del mercado interno ecuatoriano

a. Preguntas de investigación

1. ¿Qué tipo de mercadería y actividades económicas concentran la mayor proporción de las operaciones de la muestra?
2. ¿Existe algún patrón de diferencias al cruzar el sector al que pertenece la empresa con el tipo de mercadería que comercializan?
3. ¿Qué tan fuerte y en qué dirección es la relación entre el costo de ventas y las ventas totales generadas por las empresas?
4. ¿Cuál es el promedio de las ventas totales y existentes asimetría o alta variabilidad entre los establecimientos?

3. Análisis descriptivo

a. Análisis de variables cuantitativas

Valor vendido – Total:

El valor promedio de ventas es de $3,996,830. Sin embargo, la mediana es significativamente menor ($691,968.00). Esta inmensa diferencia entre la media y la mediana evidencia una distribución con asimetría fuertemente positiva (como se visualiza en los histogramas logarítmicos). Adicionalmente, el coeficiente de variación es del 263.12%, lo que, sumado a una desviación estándar de $10,516,571, refleja una variabilidad extrema debido a empresas gigantes que distorsionan el promedio hacia arriba

Costo de ventas - Total:

Analizando los costos, vemos que promedian los $3,248,506 (con una mediana conservadora de $530,332.50). Esta variable presenta el nivel de dispersión más alto de las tres, con un coeficiente de variación del 287.44% y una desviación estándar de $9,337,624. Al igual que en las ventas, la distribución es asimétrica y presenta valores atípicos fuertemente marcados en el límite superior.

Valor vendido – Nacional:

En cuanto a los ingresos generados internamente, el promedio asciende a $3,405,442 (con una mediana de $652,364.50). Es interesantísimo notar que este rubro local abarca casi la totalidad del promedio de las ventas generales, demostrando que la dependencia del mercado ecuatoriano es altísima en comparación con posibles exportaciones. Presenta también una variabilidad enorme con un coeficiente de variación del 269.95% y una desviación estándar de $9,193,140.

a. Análisis de variables cualitativas

Descripción actividad principal:

El sector predominante es el "Comercio al por mayor y al por menor; reparación de vehículos automotores y motocicletas", abarcando un abrumador 85.33% (256 empresas) de la base. El segundo rubro más importante son las Industrias Manufactureras, pero con apenas un 10% (30

empresas).

Tipo de Mercadería:

La distribución nos indica que el 62% de las empresas (186 observaciones) se dedican a la comercialización "Al por Mayor", mientras que el 38% restante (114 observaciones) opera "Al por Menor". Esto demuestra una clara inclinación hacia el mercado mayorista.

4. Análisis de relaciones entre variables

a. Tabla de contingencia

Para entender si la forma de vender cambia según a qué se dedica la empresa, elegimos estas dos variables:

- **Variable 1 (Tipo de Mercadería):** Si venden Al por Mayor o Al por Menor.
- **Variable 2 (Actividad Principal):** El sector de la empresa (Comercio, Manufactura, Transporte, Información, Servicios Administrativos, Salud, Enseñanza u Otros Servicios).

Objetivo: Averiguar si vender por mayor o por m 5enor depende del sector económico al que pertenece el negocio.

1. Código en R para la Tabla de Contingencia y Gráfico

```
# Cargar librería para gráficos
 library(ggplot2)

# 1. Crear la tabla de contingencia con las cantidades de empresas (frecuencias absolutas)
 tabla_absoluta <- table(datos$Tipo_Mercaderia, datos$Actividad_Principal)
 print("--- Cantidad de Empresas ---")
 print(tabla_absoluta)

# 2. Calcular los porcentajes dentro de cada sector económico (%)
 tabla_porcentajes <- prop.table(tabla_absoluta, margin = 2) * 100
 print("--- Porcentajes por Sector Económico (%) ---")
 print(round(tabla_porcentajes, 2))

# 3. Dibujar el gráfico de barras comparativo
 ggplot(datos, aes(x = Actividad_Principal, fill = Tipo_Mercaderia)) +
   geom_bar(position = "dodge") +
   labs(
     title = "Relación entre Sector Económico y Tipo de Mercadería",
     x = "Actividad Económica Principal",
     y = "Cantidad de Empresas",
     fill = "Tipo de Mercadería"
   ) +
   theme_minimal() +
   theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

2. Tablas de Resultados

Tabla 1: Frecuencias Absolutas (Número exacto de empresas por sector y tipo de venta)

Tipo de Mercadería	Comercio	Manufactura	Información	Transporte	Serv. Adm.	Salud	Enseñanza	Otros Serv.	Total
Al por Mayor	156	25	2	0	2	0	1	0	186
Al por Menor	100	5	2	4	0	1	0	1	114
Total	**256**	**30**	**4**	**4**	**2**	**1**	**1**	**1**	**300**

Tabla 2: Frecuencias Relativas (Porcentaje que representa cada tipo de venta dentro de su sector)

Tipo de Mercadería	Comercio (%)	Manufactura (%)	Información (%)	Transporte (%)	Serv. Adm. (%)	Salud (%)	Enseñanza (%)	Otros Serv. (%)	Promedio Total (%)
Al por Mayor	60.94%	83.33%	50.00%	0.00%	100.00%	0.00%	100.00%	0.00%	62.00%
Al por Menor	39.06%	16.67%	50.00%	100.00%	0.00%	100.00%	0.00%	100.00%	38.00%
Total	**100.00%**	**100.00%**	**100.00%**	**100.00%**	**100.00%**	**100.00%**	**100.00%**	**100.00%**	**100.00%**

3. Explicación e Interpretación de los Resultados

- **Lo que pasa en el total de la muestra:** De las 300 empresas estudiadas, el 62% (186 empresas) vende Al por Mayor y el 38% restante (114 empresas) vende Al por Menor. En general, en nuestra base predominan las ventas al por mayor.

- **¿Cómo se comporta el sector Comercio?** El Comercio es el grupo más grande con 256 empresas (representa el 85.33% del total). Dentro de este grupo, 6 de cada 10 empresas (60.94%) se dedican a vender al por mayor, mientras que casi 4 de cada 10 (39.06%) venden al por menor.

- **¿Cómo se comporta la Manufactura?** En las fábricas e industrias (30 empresas en total), la preferencia por vender al por mayor es mucho más alta: alcanza un 83.33% (25 empresas). Esto es lógico porque las fábricas producen en grandes volúmenes para abastecer a distribuidores y almacenes, y casi no le venden directo al consumidor final.

- **Sectores más pequeños:** Sectores como Transporte, Salud y Otros Servicios venden únicamente al por menor en esta muestra, mientras que Servicios Administrativos y Enseñanza aparecen vendiendo solo al por mayor.

b. Análisis de correlación

Para estudiar la relación cuantitativa entre dos variables numéricas de interés, seleccionamos las dos variables principales de ingresos y costos de la base de datos:

- **Variable 1:** Valor vendido total (ventas_totales)
- **Variable 2:** Costo de venta total (costo_venta_total)

Objetivo: Evaluar si las empresas que generan mayores ingresos por ventas totales también incurren de forma proporcional en costos de venta totales más altos.

1. Código en R para el Coeficiente de Correlación y Gráfico de Dispersión

```
# 1. Calcular la correlación entre Valor Vendido Total y Costo de Venta Total
 r1 <- cor(datos$ventas_totales, datos$costo_venta_total, use = "complete.obs")
 print(paste("Correlación Valor Vendido Total vs Costo de Venta Total:", round(r1, 4)))

# 2. Gráfico de dispersión (Valor Vendido Total vs. Costo de Venta Total)
 ggplot(datos, aes(x = costo_venta_total, y = ventas_totales)) +
   geom_point(color = "#2b5c8f", alpha = 0.6) +
   geom_smooth(method = "lm", color = "red", se = FALSE) +
   labs(
     title = "Relación entre Valor Vendido Total y Costo de Venta Total",
     x = "Costo de Venta Total (USD)",
     y = "Valor Vendido Total (USD)"
   ) +
   theme_minimal()
```

2. Resultados de Correlación (Coeficiente r de Pearson)

Variables Analizadas	Coeficiente de Correlación (r)	Dirección e Intensidad
Valor vendido total (ventas_totales) – Costo de venta total (costo_venta_total)	**0.9889**	Positiva (Directa) - Extremadamente Fuerte

3. Interpretación del Análisis de Correlación

- **Dirección e Intensidad:** El coeficiente de correlación de Pearson entre el Valor vendido total (ventas_totales) y el Costo de venta total (costo_venta_total) es r = 0.9889. En estadística, un valor tan cercano a 1 muestra una relación positiva (directa) extremadamente fuerte.
- **Significado en el negocio:** En la práctica del negocio, esto nos dice que ambas variables se mueven juntas casi de forma perfecta: las empresas que registran un mayor Valor vendido total también asumen en la misma proporción un Costo de venta total más elevado para adquirir o producir esa mercadería.
- **Correlación no es Causalidad:** Es súper importante recordar que una correlación alta no significa causalidad directa. Tener un mayor costo de venta no 'provoca' automáticamente mayores ventas. Lo que sucede es que ambas variables crecen juntas porque responden al tamaño y al volumen de operación de cada empresa.

5. Interpretación y principales hallazgos

A partir del análisis descriptivo de la muestra de 300 empresas obtenida de la ENESEM 2024, se logró caracterizar el comportamiento comercial y financiero del sector analizado. Los resultados demuestran una alta concentración económica: el sector "Comercio" domina

abrumadoramente la base (85.33%), y la comercialización "Al por Mayor" es la modalidad predominante a nivel general (62%). Al cruzar estas variables en la tabla de contingencia, se evidenció que la naturaleza de la actividad económica influye en el canal de venta; por ejemplo, las industrias manufactureras enfocan sus operaciones casi enteramente al mercado mayorista (83.33%), mientras que el comercio general presenta una distribución más mixta.

En el ámbito financiero, el análisis de correlación (r = 0.9889) permitió confirmar que los costos de ventas y los ingresos totales se mueven de forma casi idéntica. Las empresas con mayores volúmenes de ventas asumen, en una proporción directa y simétrica, costos operativos más altos. Aunque la estadística descriptiva no establece que los costos causen las ventas directamente, sí refleja la escalabilidad lógica asociada al tamaño y volumen de las operaciones de cada empresa.

a. Hallazgos principales

- **Concentración de la actividad comercial:** El tejido empresarial de la muestra está fuertemente enfocado en el comercio general y en las operaciones al por mayor, dejando a la manufactura y los servicios en una clara minoría.
- **Estrategia dictada por el sector:** Las fábricas e industrias manufactureras dependen de canales de venta mayoristas, mientras que sectores de servicios puntuales (como transporte y salud) operan de forma exclusivamente minorista.
- **Escalabilidad y alta variabilidad financiera:** Existe una relación lineal positiva extremadamente fuerte entre el valor vendido total y el costo de ventas. Además, las métricas de dispersión revelaron una altísima variabilidad y asimetría, indicando que unas pocas "empresas gigantes" mueven la gran mayoría del dinero en Ecuador.

b. Preguntas que se pudieron responder mediante la estadística descriptiva

- ¿Qué tipo de mercadería y actividades económicas concentran la mayor proporción de las operaciones de la muestra?

  La actividad económica que concentra la gran mayoría de las operaciones es el "Comercio" (que incluye comercio al por mayor, menor y reparación de vehículos), abarcando el 85.33% de la muestra con 256 empresas. En cuanto al tipo de mercadería, predominan las ventas "Al por Mayor", representando el 62% del total de las observaciones analizadas.

- ¿Existe algún patrón o diferencia al cruzar el sector al que pertenece la empresa con el tipo de mercadería que comercializan?

  Sí, se observan diferencias claras según la naturaleza del sector:

  - **Comercio:** Tiene una distribución mixta, donde el 60.94% vende al por mayor y el 39.06% al por menor.
  - **Manufactura:** Muestra un patrón fuertemente mayorista, dedicando el 83.33% de sus operaciones a las ventas al por mayor.
  - **Sectores de Servicios (Transporte, Salud, Otros Servicios):** En esta muestra operan de forma exclusivamente minorista (100% al por menor).
  - **Servicios Administrativos y Enseñanza:** Se enfocan de manera exclusiva en canales mayoristas (100% al por mayor).

- ¿Qué tan fuerte y en qué dirección es la relación financiera entre el costo de ventas y las ventas totales?

  La relación financiera entre ambas variables es positiva (directa) y extremadamente fuerte,

confirmada por un coeficiente de correlación de Pearson de r = 0.9889. Esto indica que ambas métricas se mueven casi de forma perfecta en la misma dirección; es decir, las empresas que generan un mayor valor de ventas totales asumen de forma altamente proporcional un costo de ventas más elevado para sostener ese nivel de operación.

c. **Limitaciones**

- **Estadística Inferencial (Pruebas de Hipótesis):** Aunque el comercio mayorista predomina en esta muestra aleatoria de 300 datos, se requieren pruebas inferenciales y estimaciones de intervalos para confirmar si esta proporción es generalizable a la población total de empresas de Ecuador.
- **Modelos de Regresión Lineal:** La correlación casi perfecta (r = 0.9889) indica una asociación fuerte, pero la estadística descriptiva no proporciona una ecuación matemática que permita predecir con exactitud cuál será el costo de ventas si una empresa proyecta ingresos por $10 millones.
- **Análisis Multivariado de Asimetría:** No es posible determinar qué otras variables (como número de empleados, ubicación geográfica o años en el mercado) están causando la enorme dispersión y los valores atípicos en las ventas, lo cual requeriría modelos de regresión múltiple.

6. Declaración y verificación del uso de Inteligencia Artificial

a. Uso 1: Selección y Organización del análisis estadístico

Herramienta utilizada:

Microsoft Copilot.

Propósito:

Recibir orientación para estructurar el informe y organizar el análisis de la base de datos

Prompt utilizado:

"Tengo una base de datos con 11217 observaciones y 13 variables. Necesito seleccionar 3 variables cuantitativas y 2 cualitativas para un proyecto de Probabilidad y Estadística y elaborar la estructura del informe"

Respuesta obtenida:

La herramienta sugirió seleccionar las variables venta totales, costo de venta total, valor nacional, tipo mercado y descripción actividad principal, además de proponer una estructura organizada para el informe.

Decisión del equipo:

Se revisaron las variables sugeridas y se decidió utilizarlas porque permitían cumplir con los requisitos del proyecto y responder las preguntas planteadas.

Verificación realizada:

La selección fue comparada con los requisitos establecidos en la guía del proyecto y con la descripción de cada variable dentro de la base de datos. También se verificó que las variables elegidas permitieran realizar análisis descriptivos, tablas de contingencia y análisis de correlación

b. Uso 2: Elaboración de código en R

Herramienta utilizada:

Microsoft Copilot.

Propósito:

Obtener ejemplos de código en R para el procesamiento y análisis de la base de datos

Prompt utilizado:

"Genera un script en R para seleccionar variables, obtener una muestra aleatoria de 300 observaciones, calcular estadísticas descriptivas y generar gráficos "

Respuesta obtenida:

Se obtuvo un conjunto de instrucciones y fragmentos de código para realizar la selección de variables, crear la muestra y elaborar gráficos y estadísticas descriptivas.

Decisión del equipo:

Se revisaron las variables sugeridas y se decidió utilizarlas porque permitían cumplir con los requisitos del proyecto y responder las preguntas planteadas.

Verificación realizada:

Se ejecutó cada sección del código en RStudio y se compararon los resultados con tablas generadas automáticamente por R mediante funciones como summary(), table(), mean(), median(), sd() y cor(). También se verificó que las dimensiones de la muestra fueran de 300 observaciones y 5 variables.

c. Uso 3: Interpretación de resultados

Herramienta utilizada:

Microsoft Copilot.

Propósito:

Revisar apoyo para redactar interpretaciones estadísticas de los resultados obtenidos

Prompt utilizado:

"Ayúdame a interpretar el coeficiente de correlación obtenido entre ventas totales y

costo de venta"

Respuesta obtenida:

La herramienta explicó el significado estadístico de los coeficientes de correlación y sugirió ejemplos de redacción.

Decisión del equipo:

Las interpretaciones fueron contrastadas con los resultados obtenidos en R y posteriormente redactadas con las palabras propias.

Verificación realizada:

Se revisó que las conclusiones fueran coherentes con los valores calculados y con los gráficos generados durante el análisis.

La inteligencia artificial fue utilizada únicamente como herramienta de apoyo para la organización del trabajo, la generación de ejemplos de código y la interpretación de resultados. Todas las decisiones estadísticas, la selección de variables, la ejecución de los análisis, la validación de los resultados y las conclusiones realizadas y verificadas por los integrantes del equipo mediante RStudio y el análisis directo de los datos.

7. Referencias Bibliográficas